

MINI PROJET

Analyse Prédictive du Risque de Maladie Cardiaque

Année Universitaire 2025-2026



Réalisé par :
Boubker CHEYOUKH

HESTIM Engineering & Business School

Table des Matières et Figures

1. Introduction et Contexte Médical.....	3
2. Exploration et Analyse des Données.....	3
Figure 1 : Aperçu des données et distribution.....	3
3. Méthodologie et Choix Techniques.....	4
Figure 2 : Variance expliquée par l'ACP.	5
4. Modélisation et Évaluation des Performances.....	6
5. Application de Déploiement.....	7

1. Introduction et Contexte Médical

Les maladies cardiovasculaires (CHD) constituent une préoccupation majeure de santé publique mondiale. Dans le cadre de la médecine préventive, l'utilisation de l'intelligence artificielle permet d'identifier les profils à risque avant l'apparition de symptômes cliniques graves.

Ce projet a pour ambition de concevoir un pipeline de Machine Learning robuste capable de prédire la présence de maladie coronarienne à partir de biomarqueurs non invasifs (tabagisme, cholestérol, hérédité, etc.). Nous portons une attention particulière à l'interprétabilité des modèles et à leur intégration dans un outil d'aide à la décision clinique.

2. Exploration et Analyse des Données

Le dataset 'CHD.csv' comprend 462 patients et 10 variables. Une analyse exploratoire rigoureuse est le prérequis indispensable à toute modélisation fiable.



Figure 1 : Aperçu des données brutes et visualisation des structures.

Observations Clés :

- **Qualité des Données** : La heatmap des valeurs manquantes a confirmé l'absence de données nulles, garantissant l'intégrité du jeu de données.
- **Déséquilibre de Classe** : La variable cible 'chd' présente une distribution inégale, justifiant l'usage de métriques adaptées (F1-Score) et de techniques de rééquilibrage (SMOTE) pour certains modèles.
- **Corrélations** : Les variables 'tobacco', 'ldl' et 'age' montrent une corrélation positive significative avec la cible.

3. Méthodologie et Choix Techniques

Notre protocole expérimental repose sur une séparation stricte des données (Train/Test Split 67%/33%) avec une stratification sur la variable cible pour préserver la distribution des classes.

3.1 Pipeline de Prétraitement (Scikit-Learn)

L'hétérogénéité des données (numériques continues et catégorielles) impose des traitements différenciés encapsulés dans un *ColumnTransformer* :

- **Standardisation (StandardScaler)** : Centrage et réduction des variables numériques. Essentiel pour la Régression Logistique et le KNN qui sont sensibles aux échelles (distance euclidienne).
- **Encodage (OneHotEncoder)** : Transformation de la variable binaire 'famhist' (Present/Absent) en vecteurs numériques.
- **Imputation** : Stratégies de remplissage par la moyenne (numérique) et le mode (catégoriel) pour assurer la robustesse en production.

3.2 Réduction de Dimensionnalité (ACP)

L'Analyse en Composantes Principales (ACP) a été appliquée pour décorrélérer les variables et réduire le bruit.




Figure 2 : Courbe de variance cumulée déterminant le seuil optimal.

L'analyse montre qu'il est nécessaire de conserver **7 composantes principales** pour capturer 90% de l'information (variance) du dataset original. Ce choix optimise le compromis biais-variance.

4. Modélisation et Évaluation

Trois architectures de modèles ont été entraînées et comparées. L'optimisation des hyperparamètres a été réalisée via *GridSearchCV* (Validation Croisée 5-folds).

4.1 Synthèse des Performances (Accuracy)

Modèle	Configuration / Hyperparamètres	Accuracy (Test)
Régression Logistique	Baseline (Sans ACP)	72.55%
Régression Logistique	ACP (7 comp.)	73.86%
K-Nearest Neighbors	ACP + SMOTE (k=19, metric=euclidean)	65.36%

Analyse : La Régression Logistique couplée à l'ACP surpasse légèrement la version sans ACP (+1.3%), validant l'intérêt de la réduction de dimension pour généraliser. Le modèle KNN, malgré l'équilibrage SMOTE, sous-performe (65.36%), suggérant que les frontières de décision ne sont pas purement locales.

4.2 Analyse Détaillée du Meilleur Modèle (LogReg + ACP)

Au-delà de l'accuracy globale, il est crucial d'analyser la capacité du modèle à détecter les cas positifs (Maladie).

Classe	Precision	Recall	F1-Score	Support
0 (Sain)	0.74	0.89	0.81	100
1 (Malade)	0.67	0.42	0.51	53
Global	0.72	0.73	0.71	153

Interprétation : Le modèle excelle à identifier les patients sains (Recall 0.89). Cependant, le Recall de 0.42 pour la classe 'Malade' indique que le modèle manque encore de sensibilité pour le dépistage massif, un point d'amélioration futur (ajustement du seuil de décision).

5. Déploiement (Streamlit)

L'aboutissement du projet est une application Web interactive permettant l'inférence en temps réel.

- **Architecture :** Chargement optimisé du modèle sérialisé (.pkl) via Joblib.
- **UX/UI :** Interface réactive avec feedback visuel immédiat (Jauges de risque).
- **Transparence :** Affichage des probabilités de prédiction pour nuancer le diagnostic binaire.

6. Conclusion et Perspectives

Ce projet valide une approche data-driven pour la prédiction du risque cardiaque avec une précision de près de 74%. Les perspectives d'amélioration incluent l'exploration de modèles non-linéaires plus complexes (Random Forest, XGBoost) et l'enrichissement du dataset pour améliorer la sensibilité (Recall) sur les cas pathologiques.

Ressources du Projet

Code Source (GitHub) : https://github.com/Boubker-CHK/heart_disease

Application Live : <https://heartdisease-irr4bonqfaqeoqqhszhxzx.streamlit.app/>